Obliczenia naukowe — Lista 1: sprawozdanie

Krzysztof Zając

Oznaczenia: t — liczba bitów mantysy (z bitem ukrytym), $u = 2^{-t}$ — precyzja arytmetyki (ϵ z wykładu), $\delta = 2^{-52}$.

Zad. 1 — macheps, eta, MAX

Typ	t	macheps	$\eta = \text{MIN}_{\text{sub}}$	`floatmin`$= \text{MIN}_{\text{nor}}$	MAX
Float16	11	$2^{-10} \approx 9{,}77 \cdot 10^{-4}$	$2^{-24} \approx 5{,}96 \cdot 10^{-8}$	$2^{-14} \approx 6{,}10 \cdot 10^{-5}$	65504
Float32	24	$2^{-23} \approx 1{,}19 \cdot 10^{-7}$	$2^{-149} \approx 1{,}40 \cdot 10^{-45}$	$2^{-126} \approx 1{,}18 \cdot 10^{-38}$	$3{,}40 \cdot 10^{38}$
Float64	53	$2^{-52} \approx 2{,}22 \cdot 10^{-16}$	$2^{-1074} \approx 4{,}94 \cdot 10^{-324}$	$2^{-1022} \approx 2{,}23 \cdot 10^{-308}$	$1{,}80 \cdot 10^{308}$

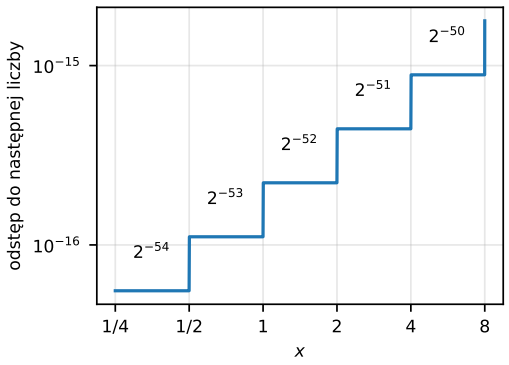
Tabela 1: Wartości wyznaczone iteracyjnie. Są równe wartościom z `eps`, `nextfloat(0)`, `floatmin`, `floatmax`.

- Wartości iteracyjne zgadzają się z `float.h` dla Float32 (`FLT_EPSILON`, `FLT_MAX`) i Float64 (`DBL_EPSILON`, `DBL_MAX`). Float16 nie ma odpowiednika w C.
- macheps $= 2^{1-t} = 2u$. Dla Float64: macheps $= 2^{-52}$, $u = 2^{-53} \approx 1{,}11 \cdot 10^{-16}$ (granica błędu względnego zaokrąglenia do najbliższej).
- $\eta =$ `nextfloat(0)` $= \text{MIN}_{\text{sub}} = 2^{e_{\min}-t+1}$, $e_{\min} = -14, -126, -1022$.
- `floatmin` $= \text{MIN}_{\text{nor}} = 2^{e_{\min}}$ (najmniejsza liczba znormalizowana). $\text{MIN}_{\text{nor}}/\text{MIN}_{\text{sub}} = 2^{t-1}$ — tyle jest liczb podnormalnych w każdym typie.
- MAX $= (2 - 2^{1-t})\, 2^{e_{\max}}$, $e_{\max} = 15, 127, 1023$. Dla Float16: 65504.

Zad. 2 — rozmieszczenie liczb Float64

x	wykładnik (11 b)	mantysa (52 b)
0,5	`01111111110`	$0 \ldots 0$
$0{,}5 + 2^{-53}$	`01111111110`	$0 \ldots 01$
1	`01111111111`	$0 \ldots 0$
$1 + \delta$	`01111111111`	$0 \ldots 01$
$1 + 2\delta$	`01111111111`	$0 \ldots 010$
$2 - \delta$	`01111111111`	$1 \ldots 1$
2	`10000000000`	$0 \ldots 0$
$2 + 2^{-51}$	`10000000000`	$0 \ldots 01$
4	`10000000001`	$0 \ldots 0$

Tabela 2: `bitstring` (bit znaku = 0 pominięty).



Rysunek 1: Odstęp sąsiednich liczb Float64.

- Test: 10^6 kolejnych liczb od 1,0 i 10^3 ostatnich przed 2,0 mają `nextfloat(x)-x`$= \delta$ i $x = 1 + k\delta$. Dla 10^5 losowych $x \in [1, 2)$: $k = (x - 1)/\delta$ jest całkowite, $1 \le k \le 2^{52} - 1$. Wszystkie testy dały `true`.
- W $[1, 2)$ wykładnik jest stały, a mantysa to k zapisane binarnie. Przejście $2 - \delta \to 2$ zwiększa wykładnik.
- $[\frac{1}{2}, 1]$: $x = \frac{1}{2} + k\,\delta/2$, krok 2^{-53} (2 razy gęściej).
- $[2, 4]$: $x = 2 + 2k\delta$, krok 2^{-51} (2 razy rzadziej).
- Ogólnie $[2^e, 2^{e+1})$: $x = 2^e(1 + k\delta)$, krok 2^{e-52}, zawsze 2^{52} liczb. Odstęp bezwzględny rośnie z x, względny pozostaje w $(2^{-53}, 2^{-52}]$.

Zad. 3 — $x \cdot (1/x) \neq 1$

- Skan od `nextfloat(1.0)` w górę zatrzymuje się na pierwszym kontrprzykładzie, więc (a) i (b) to ta sama liczba:
  $x = 1{,}000000057228997 = 1 + 257\,736\,490 \cdot 2^{-52}$.

- $\mathrm{fl}\big(x \cdot \mathrm{fl}(1/x)\big) = 0{,}9999999999999999 = 1 - 2^{-53}$ (poprzednik 1,0, błąd 1 ulp).
- Wniosek: dwa zaokrąglenia (dla $1/x$ i dla iloczynu) wystarczą, żeby $x \cdot (1/x) \neq 1$. Nie testować odwrotności przez `==1`.

Zad. 4 — iloczyn skalarny

	Float32		Float64	
Metoda	wynik	błąd bezwzgl.	wynik	błąd bezwzgl.
(a) w przód	$-0{,}49994430$	$5{,}0 \cdot 10^{-1}$	$+1{,}0252 \cdot 10^{-10}$	$1{,}1 \cdot 10^{-10}$
(b) w tył	$-0{,}45434570$	$4{,}5 \cdot 10^{-1}$	$-1{,}5643 \cdot 10^{-10}$	$1{,}5 \cdot 10^{-10}$
(c) malejąco	$-0{,}5$	$5{,}0 \cdot 10^{-1}$	0	$1{,}0 \cdot 10^{-11}$
(d) rosnąco	$-0{,}5$	$5{,}0 \cdot 10^{-1}$	0	$1{,}0 \cdot 10^{-11}$

Tabela 3: Wartość dokładna: $-1{,}00657107 \cdot 10^{-11}$.

- Żaden wynik nie jest wiarygodny. Float32: błąd $\approx 0{,}5$, czyli ok. 10^{10} razy więcej niż wynik. Float64: (a), (b) mają błędny znak, (c), (d) dają 0 (błąd względny 100%).
- Przyczyna to uwarunkowanie zadania: $\kappa = \sum |x_i y_i| \,/\, |\sum x_i y_i| \approx 5{,}5 \cdot 10^{17} \gg 1/u = 2^{53} \approx 9 \cdot 10^{15}$. Składniki rzędu $\pm 2{,}76 \cdot 10^6$ znoszą się do 10^{-11}.
- Już same iloczyny w Float64 są zaokrąglone z błędem do $\frac{1}{2}\mathrm{ulp}(2{,}76 \cdot 10^6) = 2^{-32} \approx 2{,}3 \cdot 10^{-10} \gg |\text{wynik}|$. Zmiana kolejności sumowania tego nie naprawia.
- Kolejność zmienia wynik ((a)≠(b)), ale nie jego jakość. (c) i (d) dają identyczne wyniki w obu precyzjach.
- Poprawny wynik wymaga wyższej precyzji także dla iloczynów (np. `BigFloat`).

Zad. 5 — $f(x) = \sqrt{x^2+1} - 1$ i $g(x) = x^2/(\sqrt{x^2+1}+1)$

Błąd względny δ liczony względem wartości z `BigFloat` (512 bitów), $x = 8^{-k}$.

k	x	$f(x)$	$g(x)$	δ_f	δ_g
1	$1{,}25 \cdot 10^{-1}$	$7{,}78222 \cdot 10^{-3}$	$7{,}78222 \cdot 10^{-3}$	$8{,}4 \cdot 10^{-15}$	$7{,}1 \cdot 10^{-18}$
2	$1{,}56 \cdot 10^{-2}$	$1{,}22063 \cdot 10^{-4}$	$1{,}22063 \cdot 10^{-4}$	$6{,}8 \cdot 10^{-13}$	$8{,}3 \cdot 10^{-17}$
3	$1{,}95 \cdot 10^{-3}$	$1{,}90735 \cdot 10^{-6}$	$1{,}90735 \cdot 10^{-6}$	$1{,}8 \cdot 10^{-12}$	$4{,}3 \cdot 10^{-18}$
5	$3{,}05 \cdot 10^{-5}$	$4{,}65661 \cdot 10^{-10}$	$4{,}65661 \cdot 10^{-10}$	$2{,}3 \cdot 10^{-10}$	$1{,}1 \cdot 10^{-19}$
8	$5{,}96 \cdot 10^{-8}$	$1{,}77636 \cdot 10^{-15}$	$1{,}77636 \cdot 10^{-15}$	$8{,}9 \cdot 10^{-16}$	$1{,}6 \cdot 10^{-30}$
9	$7{,}45 \cdot 10^{-9}$	0	$2{,}77556 \cdot 10^{-17}$	1	$1{,}4 \cdot 10^{-17}$
10	$9{,}31 \cdot 10^{-10}$	0	$4{,}33681 \cdot 10^{-19}$	1	$2{,}2 \cdot 10^{-19}$

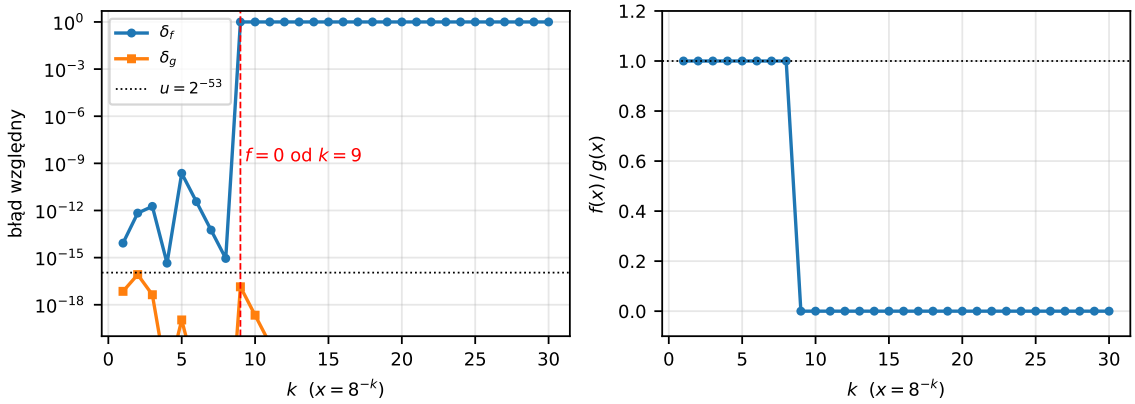
Tabela 4: Wybrane wiersze ($k = 1, \ldots, 179$ w pliku wyjściowym).

- Wiarygodne jest g: $\delta_g \leq 8{,}3 \cdot 10^{-17} < u$ dla $k \leq 178$. Dla $k \geq 8$ błąd jest jeszcze mniejszy, bo $\sqrt{x^2+1}+1 = 2$ i $g = x^2/2$ jest potęgą dwójki (błąd metody $\approx x^2/4$).
- f jest niewiarygodne. Odejmowanie bliskich liczb ($\sqrt{x^2+1} \approx 1$) daje $\delta_f \lesssim u/(x^2/2) \propto 64^k$. Błąd rośnie niemonotonicznie ($k = 4, 8$ trafione szczęśliwie), a to oszacowanie jest górne.
- Od $k = 9$: $x^2 = 2^{-6k} < 2^{-53}$, więc $\mathrm{fl}(1 + x^2) = 1$ i $f = 0$ ($\delta_f = 100\%$).
- $g = 0$ dopiero dla $k = 179$ (podpływ: $x^2/2 \leq \mathrm{MIN}_{\mathrm{sub}}/2$). To limit zakresu, nie algorytmu.
- Wniosek: przekształcić wzór tak, by uniknąć odejmowania bliskich liczb.

Zad. 6 — pochodna różnicowa $f(x) = \sin x + \cos 3x$, $x_0 = 1$

Dokładnie: $f'(1) = \cos 1 - 3\sin 3 = 0{,}1169422816885382$. Błąd $E = |f'(x_0) - \tilde{f}'(x_0)|$, $h = 2^{-n}$.

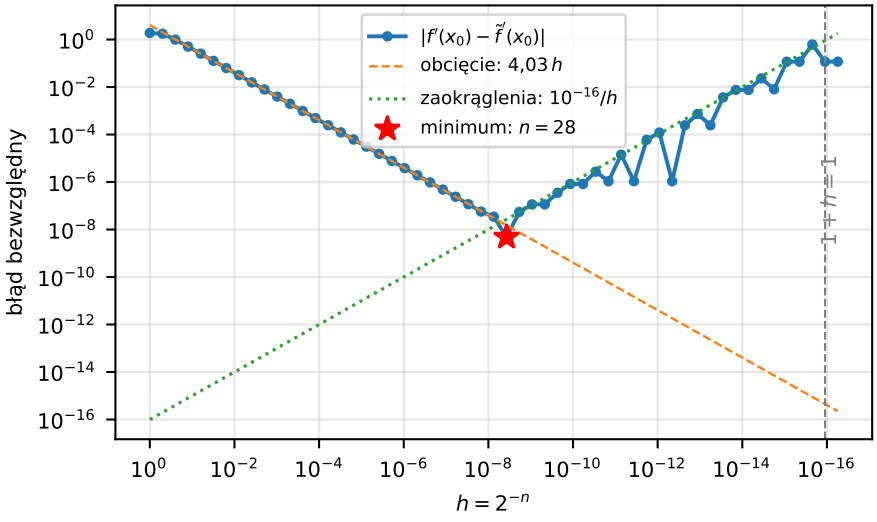
- $n \leq 26$: dominuje błąd obcięcia $\approx |f''(x_0)|\, h/2 = 4{,}03\, h$ ($f''(1) = -\sin 1 - 9\cos 3 \approx 8{,}07$). Przykład: $n = 20$, $E = 3{,}8 \cdot 10^{-6}$.



Rysunek 2: Lewy: błąd względny δ_f, δ_g. Prawy: stosunek f/g (powinien być równy 1).

n	h	$\tilde{f}'(x_0)$	E	$\mathrm{fl}(1+h)$
0	1	2,017989	1,9	2
10	$9{,}77 \cdot 10^{-4}$	0,120882	$3{,}9 \cdot 10^{-3}$	$1 + 2^{-n}$
20	$9{,}54 \cdot 10^{-7}$	0,116946	$3{,}8 \cdot 10^{-6}$	$1 + 2^{-n}$
26	$1{,}49 \cdot 10^{-8}$	0,1169423386	$5{,}7 \cdot 10^{-8}$	$1 + 2^{-n}$
28	$3{,}73 \cdot 10^{-9}$	0,1169422865	$4{,}8 \cdot 10^{-9}$	$1 + 2^{-n}$
30	$9{,}31 \cdot 10^{-10}$	0,1169421673	$1{,}1 \cdot 10^{-7}$	$1 + 2^{-n}$
40	$9{,}09 \cdot 10^{-13}$	0,116821	$1{,}2 \cdot 10^{-4}$	$1 + 2^{-n}$
50	$8{,}88 \cdot 10^{-16}$	0	$1{,}2 \cdot 10^{-1}$	$1 + 2^{-n}$
51	$4{,}44 \cdot 10^{-16}$	0	$1{,}2 \cdot 10^{-1}$	$1 + 2^{-n}$
52	$2{,}22 \cdot 10^{-16}$	$-0{,}5$	$6{,}2 \cdot 10^{-1}$	$1 + 2^{-52}$
53	$1{,}11 \cdot 10^{-16}$	0	$1{,}2 \cdot 10^{-1}$	1
54	$5{,}55 \cdot 10^{-17}$	0	$1{,}2 \cdot 10^{-1}$	1

Tabela 5: Wybrane wiersze ($n = 0, \ldots, 54$ w pliku wyjściowym).



Rysunek 3: Błąd pochodnej w funkcji h (skala log–log).

- Minimum E dla $n = 28$ ($h = 3{,}7 \cdot 10^{-9}$, $E = 4{,}8 \cdot 10^{-9}$), rząd $\sqrt{\text{macheps}} \approx 1{,}5 \cdot 10^{-8}$. Sąsiednie $n = 27, 29$ dają $3{,}5 \cdot 10^{-8}$ i $5{,}5 \cdot 10^{-8}$, więc minimum jest częściowo przypadkowe.
- $n > 28$: $E \approx 10^{-16}/h$ ($n = 30$: $1{,}1 \cdot 10^{-7}$; $n = 40$: $1{,}2 \cdot 10^{-4}$; $n = 45$: $3{,}7 \cdot 10^{-3}$). To odejmowanie bliskich $f(x_0 + h) - f(x_0)$: szum zaokrągleń obliczenia f ($\text{ulp}(\sin x), \text{ulp}(\cos 3x) \approx 1{,}1 \cdot 10^{-16}$) dzielony przez h. Dalsze zmniejszanie h pogarsza wynik.
- $1 + h$: dla $n \leq 52$ jest $1 + 2^{-n}$ dokładnie, więc błąd nie pochodzi z dodawania $x_0 + h$. Dla $n \geq 53$ jest $h \leq u = 2^{-53}$ i $\text{fl}(1 + h) = 1$ (remis do parzystej), licznik $= 0$, $\tilde{f}' = 0$, $E = |f'(x_0)|$.
- $n = 50, 51$: $1 + h \neq 1$, ale $\tilde{f}' = 0$. Zmiana $f \approx f'h \approx 10^{-16}$ jest rzędu szumu obliczeń sin i cos, więc $f(x_0 + h) = f(x_0)$. Dla $n = 52$ licznik wynosi -2^{-53} (zły znak, czysty szum).

Wnioski

- Pojedyncza operacja ma błąd względny $\leq u = 2^{-53}$. Problemem jest skracanie przy odejmowaniu bliskich liczb (zad. 4, 5, 6), nie sama arytmetyka.
- Kolejność działań zmienia wynik (zad. 4), a algebraicznie równoważne wzory dają różną dokładność (zad. 5).
- Granice zakresu (podnormalne, podpływ, nadmiar) są ostre i przewidywalne (zad. 1, 5).